



Módulo VII: Introducción a Redes Neuronales y Deep Learning.

Clase 27: Perceptrón multicapa (2)





¿Ponemos a grabar el
taller?

¿QUÉ VAMOS A VER HOY?



- Repaso




- Funciones de activación
- Implementación de una red neuronal




Repasemos

Redes Neuronales

Algoritmo cuyo unidad básica de procesamiento está inspirada en la célula fundamental del sistema nervioso humano: la **neurona**




Redes Neuronales



Neurona: Unidades de procesamiento que intercambian datos o información

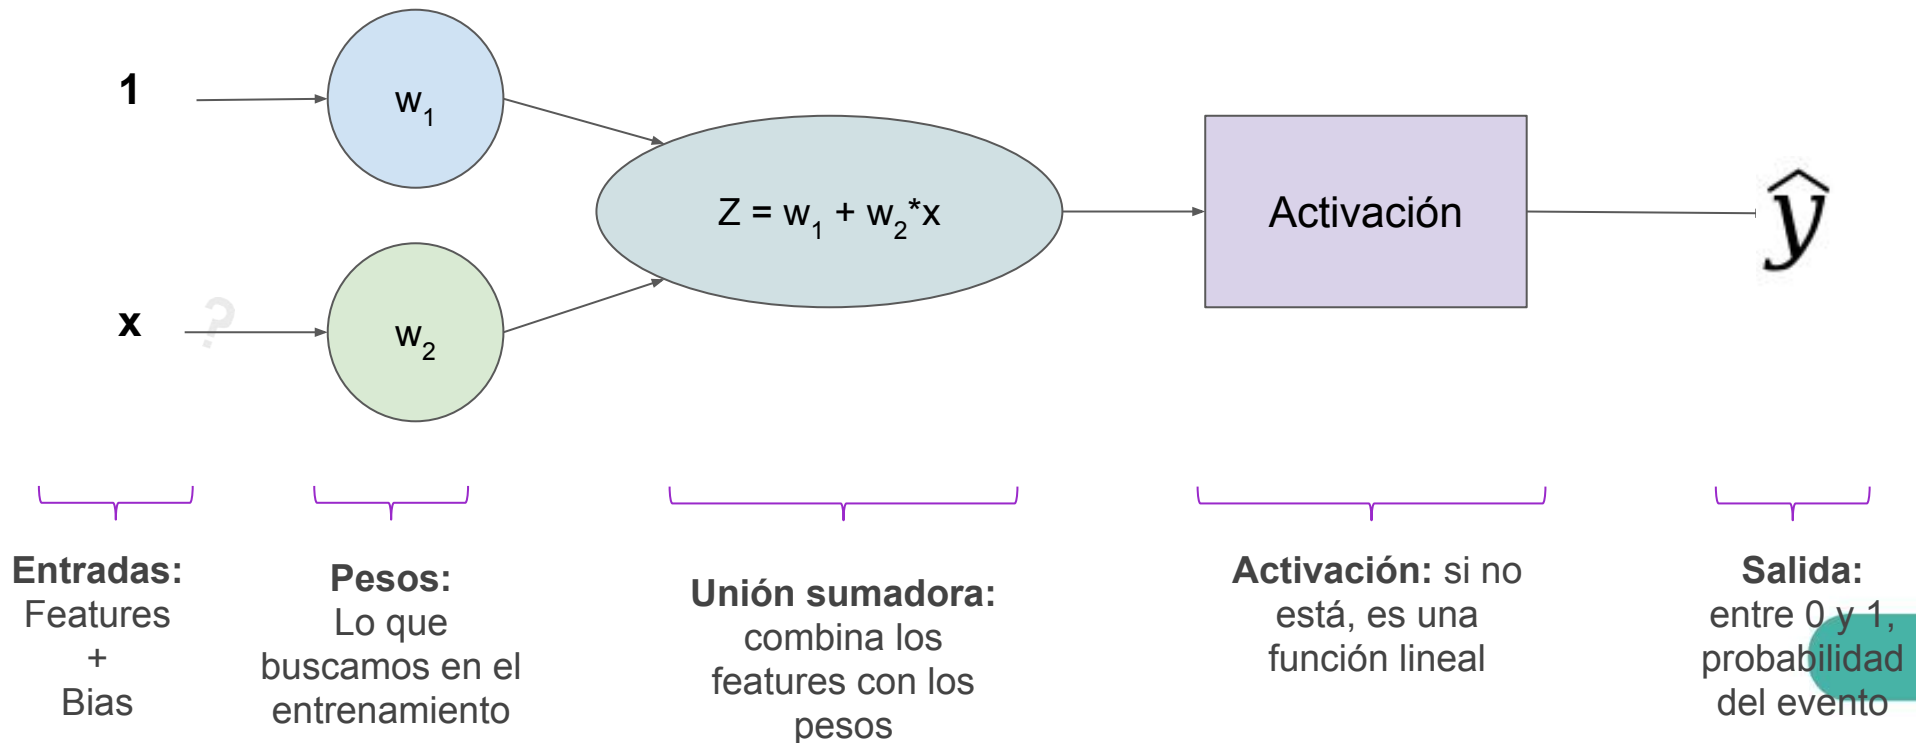
Neurona básica



Perceptrón Simple

Perceptrón simple

Necesitamos una función que, dado los features, devuelva probabilidades entre 0 y 1




Descenso por gradiente

- En cualquier algoritmo de machine learning, es necesaria una **función de costo/pérdida** que depende del problema (clasificación, regresión, etc).
- La función de costo es una función de los parámetros de la red neuronal.
- Los mejores parámetros de la red son aquellos que **minimicen la función de costo**.
- Es imposible explorar el espacio de parámetros exhaustivamente. Por lo cual, se utiliza una técnica que lo haga eficientemente: **Descenso por Gradiente**.

Función Sigmoidea

$$y(x) = \frac{1}{1 + e^{-(w_0 + w_1 x)}}$$



Transforma los valores introducidos a una escala (0,1), donde los valores altos tienen de manera asintótica a 1 y los valores muy bajos tienden de manera asintótica a 0.

Entropía cruzada

Pérdida para una instancia


$$L(\hat{y}, y) = -y * \log(\hat{y}) - (1 - y) * \log(1 - \hat{y})$$

Costo para todas las instancias


$$J(\overline{W}) = \frac{1}{n} \sum_{i=0}^{n-1} L(\hat{y}^{(i)}, y^{(i)})$$

Es una función de pérdida entre una etiqueta (y) y la probabilidad de pertenecer o no a esa etiqueta.


Forward Propagation



BACK Propagation




Perceptrón Multicapa



Cada neurona tiene sus propios pesos/parámetros.

Podemos encontrar miles a millones de parámetros para toda la red para aplicaciones comunes.


Perceptrón Multicapa



En las neuronas del perceptrón multicapa o red neuronal, se aplican los conceptos vistos:

- Descenso por gradiente
- Función de costo
- Forward Propagation
- Backpropagation

Perceptrón Multicapa



Tenemos más opciones para las funciones de activación:

- Sigmoidea
- Tanh
- ReLu
- Leaky ReLu



Funciones de activación

Función Sigmoidea

Transforma los valores introducidos a una escala (0,1), donde los valores altos tienen de manera asintótica a 1 y los valores muy bajos tienden de manera asintótica a 0.

$$y(z) = \frac{1}{1 + e^{-z}}$$

Características:

Sufre de *vanishing gradient*

Lenta convergencia.

No está centrada en el cero.

Está acotada entre 0 y 1.

Tiene un excelente rendimiento para la **capa de salida**.


Tangente hiperbólica (Tanh)

$$f(x) = \frac{2}{1 + e^{-2x}} - 1$$

Transforma los valores introducidos a una escala (-1,1), donde los valores altos tienen de manera asintótica a 1 y los valores muy bajos tienden de manera asintótica a -1.

Tangente hiperbólica (Tanh)

$$f(x) = \frac{2}{1 + e^{-2x}} - 1$$



Tangente hiperbólica (Tanh)

Características:

- Similar a la función sigmoide
- Sufre de *vanishing gradient*
- Lenta convergencia.
- Centrada en 0.
- Está acotada entre -1 y 1.
- Se utiliza para decidir entre una opción y la contraria.
- Tiene un buen rendimiento para **redes recurrentes**.


Rectified Lineal Unit (ReLU)

$$f(x) = \max(0, x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$$

Transforma los valores introducidos anulando los valores negativos y dejando los positivos tal y como entran.

Rectified Linear Unit (ReLU)

$$f(x) = \max(0, x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$$



Rectified Lineal Unit (ReLU)

Características:

- Activación Sparse: solo se activa si son positivos.
- No está acotada.
- Si bien mejora el *vanishing gradient*, pueden desactivarse demasiadas neuronas
- Tiene un buen rendimiento para **imágenes y redes convolucionales**.


Rectified Linear Unit (ReLU)

$$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ a \cdot x & \text{for } x \geq 0 \end{cases}$$

Transforma los valores introducidos multiplicando los negativos por un coeficiente rectificativo y dejando los positivos según entran.

Tangente hiperbólica (ReLU)

$$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ a \cdot x & \text{for } x \geq 0 \end{cases}$$



Tangente hiperbólica (ReLU)

Características:

- Similar a la función ReLU.
- Penaliza los negativos mediante un coeficiente rectificador.
- No está acotada.
- Soluciona el problema de vanishing gradient
- Tiene un buen rendimiento para **imágenes y redes convolucionales**.



Descanso

Nos vemos en 10 minutos



Regularización

Regularización

El objetivo de la regularización es **penalizar** parámetros/pesos muy grandes, ya que estos están asociados al overfitting.

- Regularización L2 y L1: agregan un término a la función de costo que penaliza los pesos grandes.
- **Dropout:** funciona como una capa que “apaga” neuronas de la capa anterior al azar.

Drop Out

Funciona como una capa que “apaga” neuronas de la capa anterior al azar.

- Es una técnica muy utilizada.
- Al apagar neuronas, obliga a que ninguna se aprenda “de memoria” una muestra, sino que tengan que aprender entre todas.



Repasamos en Kahoot



¿DUDAS?

FUNDACIÓN
YPF

¡Muchas gracias!

