



## Módulo VIII: Deployando modelo

### Clase 29: Puesta en producción

#### Pipelines - monitoreo de modelos





**¿Ponemos a grabar  
el taller?**

## ¿Con qué practicaremos?



- Conceptos de puesta en producción y MLOps

- Concepto de pipelines
- Monitoreo de modelos y herramientas



# ¿Repasamos?

## Etapas de un proyecto

**01**

Recolección de  
datos

**02**

Exploración y  
procesamiento

**03**

Modelado

**04**

Puesta en  
producción

## Puesta en producción



- Predecir nuevos datos
- Comunicar los resultados
- Integrar los resultados con aplicación



# Puesta en Producción

## ¿Qué es la puesta en producción?




Poner un **modelo en producción** significa que el modelo va a operar en la vida real. Va a recibir datos, va a predecir y estos resultados van a ser usados.





## ¿Por qué la puesta en producción?



Necesitamos que el modelo creado pueda ser usado por otros usuarios. Debemos tener en cuenta tres aspectos principales que pueden resultar problemáticos:

- **Acceso**
- **Compatibilidad**
- **Escala**

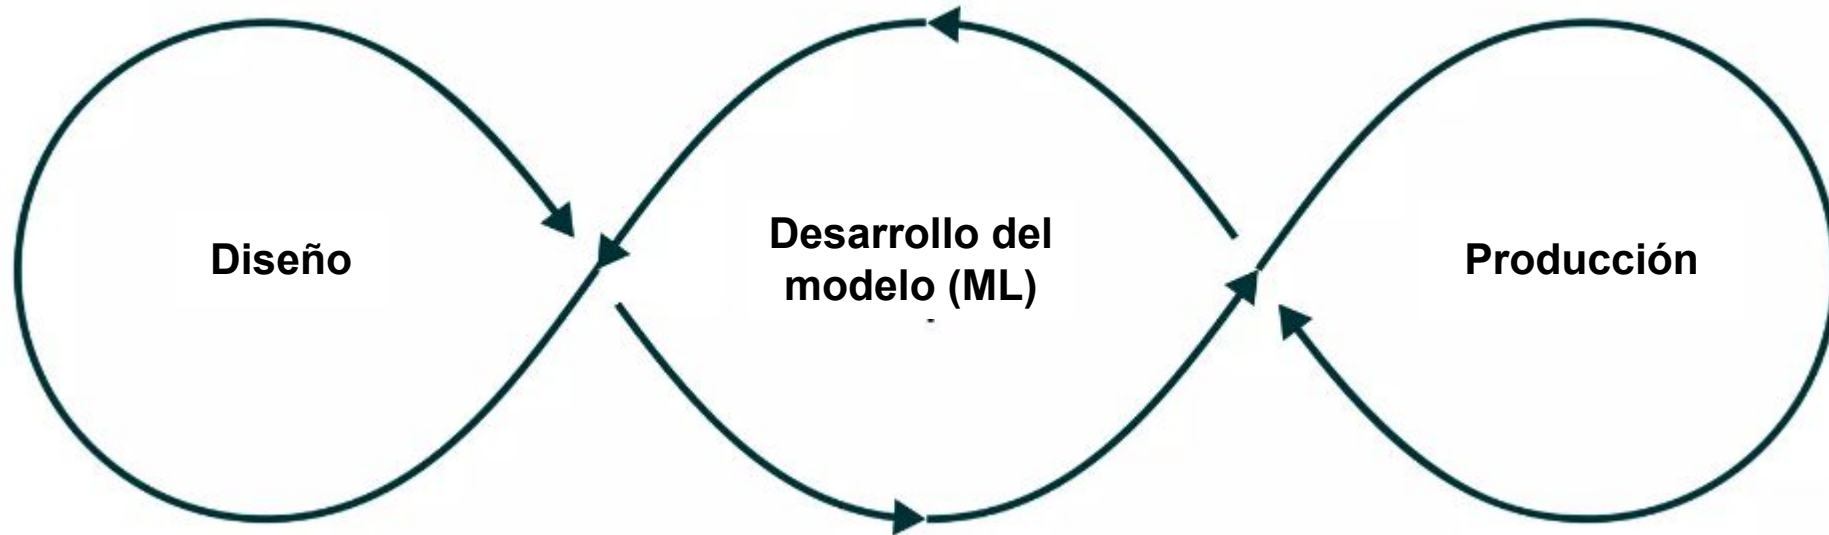
## Puesta en producción

Se estima que **90%** de los **modelos de ML** desarrollados **nunca** llegan a producción.

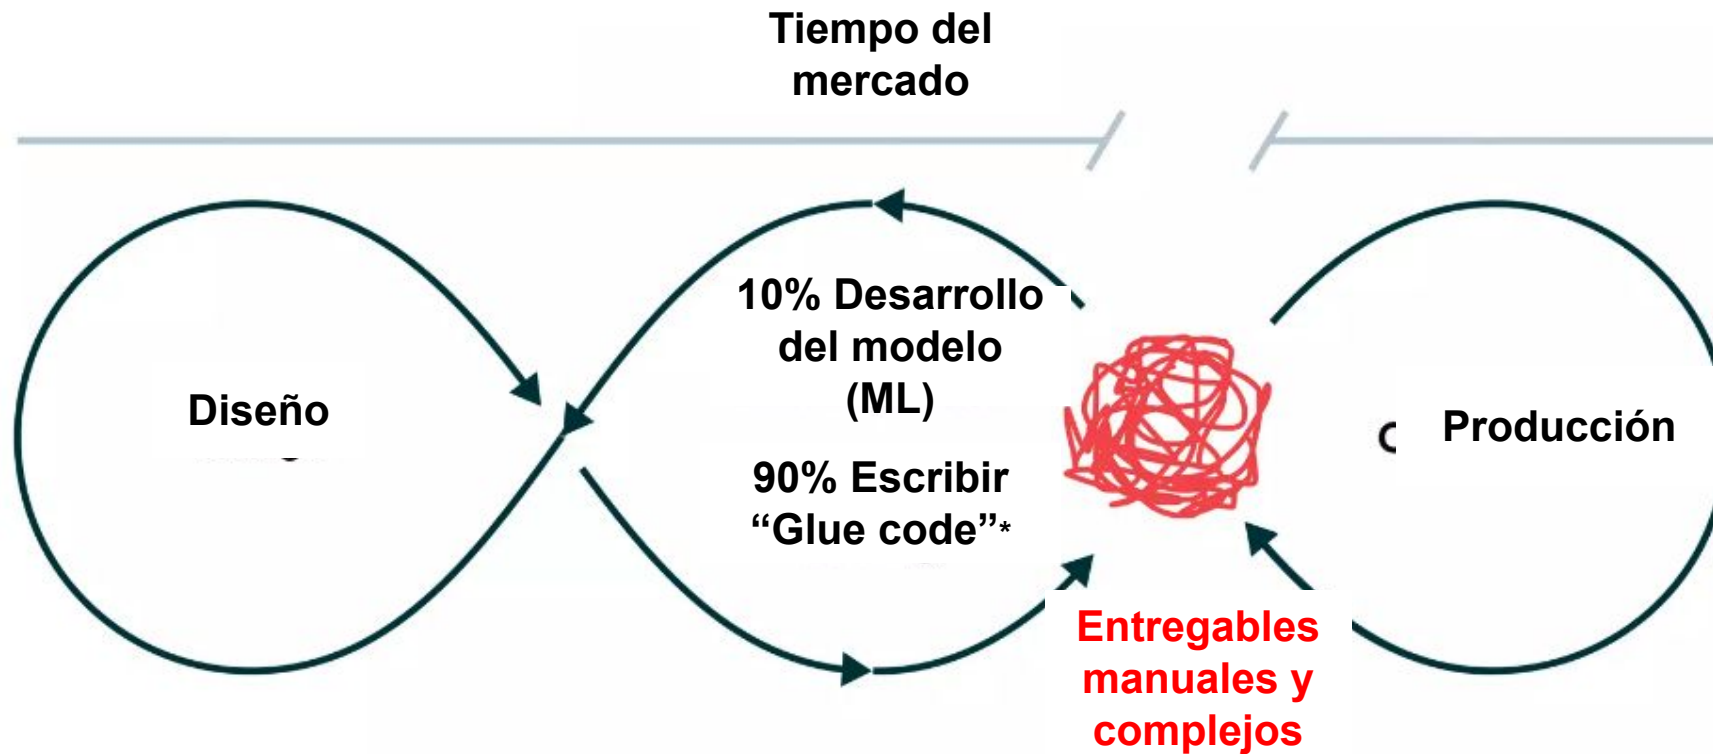


¿Por qué?

## Desarrollo de ML ideal



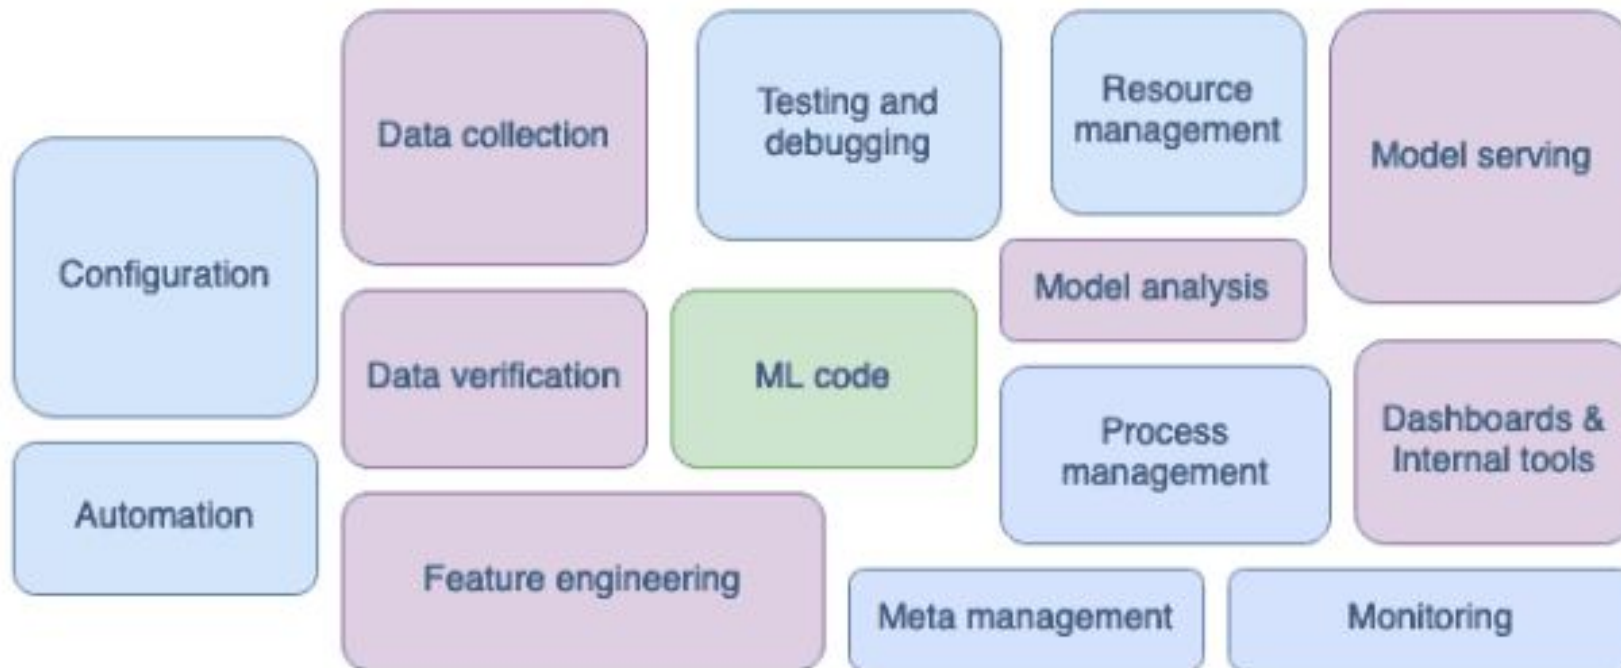
## Desarrollo de ML ideal



\* Glue code es código que sirve solamente para adaptar distintas partes del código que de otra manera serían incompatibles juntas.

## Sistema de ML

**El desarrollo del código del modelo es sólo una pequeña fracción del sistema de ML**



## Machine Learning Operations

El objetivo de **MLOps** es reducir la fricción técnica para poder llevar la idea de un modelo de ML a su puesta en producción en el **menor tiempo posible** con el **menor riesgo posible**.

## MLOps

En otras palabras, lo que busca **MLOps** es desarrollar, entrenar y desplegar modelos de ML con procedimientos automatizados que integren a los equipos de Data, desarrolladores, seguridad e infraestructura.

## MLOps

Necesitamos una infraestructura robusta:

- Acceso a los datos
- Repositorio de modelos versionados
- Pipeline automatizado
- Contenedores de software que aislen y simplifiquen la ejecución de los modelos



## Desarrollo de ML con MLOps

- Se acelera el proceso de creación de valor.
- Se reduce el riesgo durante la validación de modelos
- Se simplifica la implementación de soluciones más complejas
- Procesos de mejora de modelos más rápidos y con menos errores gracias a la automatización de procesos.
- Monitoreo y actualización continua de los modelos para que evolucionen con los datos.

## MLOps

MLOps provee herramientas en las siguientes etapas:

- Creación de los modelos y pipelines
- Evaluación de los modelos antes de su puesta en producción
- Puesta en producción
- Testeo continuo de los modelos en producción
- Deployado de los modelos
- Monitoreo y Auditoría continua

# MLOps

## Algunas herramientas:

- MLFlow
- TensorFlow Extended (TFX) Serving
- AWS SageMaker
- Kubeflow
- Databricks
- Vertex AI
- H2O



# Descanso

Nos vemos en 10 minutos



# Pipelines

## MLOps


Necesitamos una infraestructura robusta:

- Acceso a los datos
- Repositorio de modelos versionados
- **Pipeline automatizado**
- Contenedores de software que aislen y simplifiquen la ejecución de los modelos

## Flujo de trabajo

Desde qué leemos los datos hasta el momento en que obtenemos los resultados del modelo, aplicamos una serie de pasos encadenados y secuenciales, lo que se conoce como **flujo de trabajo**.

Tanto los datos de entrenamiento como los de testeo siguen el mismo camino

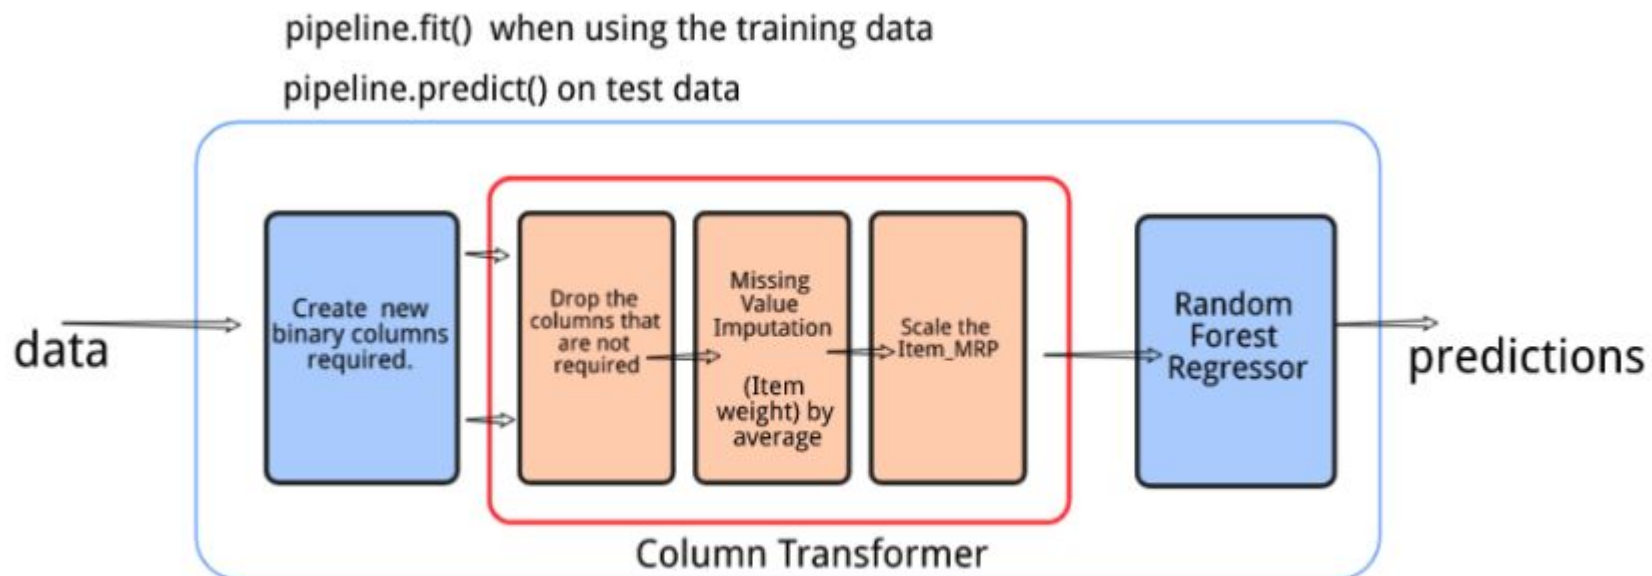


## ¿Qué es un pipeline?

Es un único objeto que nos permite empaquetar todos los pasos que van del preprocesamiento de los datos a la predicción del modelo.



## Pipeline



## Pipeline

## Pipeline: beneficios

- Simplifica el proceso y aumenta la reproducibilidad
- Evita cometer errores
- Simplifica la implementación de cross-validation y la elección de hiper parámetros.

## Pipeline: Sklearn

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.impute import SimpleImputer
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import OrdinalEncoder

categorical_encoder = OrdinalEncoder(
    handle_unknown="use_encoded_value", unknown_value=-1, encoded_missing_value=-1
)
numerical_pipe = SimpleImputer(strategy="mean")

preprocessing = ColumnTransformer(
    [
        ("cat", categorical_encoder, categorical_columns),
        ("num", numerical_pipe, numerical_columns),
    ],
    verbose_feature_names_out=False,
)

rf = Pipeline(
    [
        ("preprocess", preprocessing),
        ("classifier", RandomForestClassifier(random_state=42)),
    ]
)
rf.fit(X_train, y_train)
```



# Repasamos en Kahoot



# Descanso

Nos vemos en 10 minutos



# Monitoreo de Modelos

## ¿Qué es el monitoreo de modelos?

El monitoreo de modelos de ML mide que tan bien el modelo **desempeña** una tarea durante el entrenamiento y cuando está en **producción en tiempo real**.

## ¿Qué es el monitoreo de modelos?

- Proveer datos de que tan bien el modelo se desempeña en producción y por qué el modelo esta haciendo ciertas predicciones y como se mejorarían
- Alertar cuando haya problemas
- Proveer información para poder investigar y remediar los problemas



## ¿Por qué monitorear un modelo?

Cuando un modelo se ha puesto en producción, pueden surgir inconvenientes que llevan a que el **modelo no tenga el desempeño esperado**.

Si no “monitoreamos” el modelo y su desempeño no podremos detectar estos inconvenientes.

## ¿Por qué monitorear un modelo?

- Los datos de entrenamiento son siempre ligeramente distintos a los **datos dinámicos de producción**
- Los **valores reales** cambian, por lo que los datos con los que fueron entrenados los modelos pueden no representar la realidad con el tiempo.
- El **desempeño del modelo** empeora con el tiempo
- El modelo tiene efecto sobre el mundo real, por lo que puede cambiar la situación o problema a la cual se encontró solución mediante el modelo
- Puede haber **efectos secundarios** que no se vieron durante el entrenamiento, sobre todo en modelos muy complejos

## ¿Qué elementos monitorear?

### **Datos entrantes del modelo:**

Identificar cambios en la distribución de los datos (**Data Drift**) y de diferencias entre la distribución de datos de entrenamiento y de producción

Monitoreo operativo de fallas evidentes: ej: imágenes que son muy oscuras, mucho contraste, etc

Monitoreo estadísticas comparadas con el set de entrenamiento: media, desvío estándar, correlaciones

## ¿Qué elementos monitorear?

### Resultados del modelo



Monitoreo del desempeño y observar si cambia la distribución de las predicciones a través del tiempo  
(**concept drift**)



Monitoreo de la salud de los pipelines y de que no sufran fallos inesperados



Monitoreo de que el desempeño cumpla con los requisitos del usuario  
(ej: Velocidad de respuesta)



# Espacio práctico: entrega final

## Preparando la entrega final

En la **última clase** deberán presentar un resumen de lo trabajado durante el curso. Para ello podrán preparar una **presentación** en PowerPoint, Slides o Canva.

Tendrán 15 minutos para contar a sus compañeras la síntesis de lo aprendido.

Además, para recibir el certificado, deberán adjuntar en el aula virtual un link a su repositorio. El mismo debe incluir los ítems detallados en la siguiente hoja.

## Preparando la entrega final

Ítems a incluir en el repositorio:

- Readme (resumen, no más de un párrafo por ítem. En el mismo pueden contar de dónde obtuvieron dataset, resumen proyecto, qué objetivo se propusieron y qué descubrieron en análisis exploratorio, detalle de los modelos ajustados)
- Dataset
- Notebook con análisis exploratorio (correspondiente a pre-entrega 2)
- Notebooks donde apliquen modelos de aprendizaje supervisado y no supervisado y donde se observen resultados obtenidos (correspondientes a pre-entrega 3 y 4)
- Será valorado que cuente una historia con esos datos: que puedan demostrar cualitativamente qué preguntas se hicieron, conclusiones que sacaron con los datos, decisiones tomadas



**¿DUDAS?**



FUNDACIÓN  
**YPF**

¡Muchas gracias!

